DUOC UC

Escuela de Informática y Telecomunicaciones

Plan de Proyecto de Ciencia de Datos: Predicción de Popularidad de Canciones en Spotify

Evaluación Parcial N°3 (EP3)

Asignatura: Gestión de Proyectos de Datos (SCY1102)

Sección: SCY1102-002D

Docente: Ignacio Meza

Integrantes: N. Hormazábal, L. Concha, M. Villarroel

Octubre de 2026

1. Resumen ejecutivo

Este documento formaliza el plan de proyecto para predecir la popularidad (escala 0 a 100) de canciones en Spotify mediante aprendizaje supervisado de regresión. Desarrolla los requerimientos, el modelo financiero con retorno de inversión (ROI), el marco ético con auditoría de equidad por subgrupos, la estructura de desglose del trabajo (WBS), un cronograma de 13 semanas y los indicadores de alerta de riesgos. La metodología utilizada es CRISP-DM.

2. Contexto de negocio y objetivos

El cliente es un sello discográfico independiente cuyas divisiones de Repertorio (A&R), Programación de Playlists y Marketing requieren una herramienta predictiva objetiva para optimizar sus inversiones promocionales. El problema técnico se aborda como una regresión supervisada sobre datos tabulares (114.000 registros y 114 géneros).

Se definen tres indicadores clave de desempeño (KPI):

KPI	Meta	Descripción
KPI 1: Técnico (Go/No-Go)	MAE al menos 20% menor	Mejora relativa frente al modelo baseline ingenuo (media global).
KPI 2: Equidad (auditoría)	Brecha de MAE ≤ 30%	El MAE de ningún género supera en más de 30% al MAE global.
KPI 3: Negocio (ROI)	6 millones de streams al año	Punto de equilibrio para retornar la inversión del piloto.

3. Requerimientos

3.1 Requerimientos funcionales (matriz MoSCoW)

ID	Requerimiento funcional y criterio de aceptación	Prioridad	Necesidad de negocio
RF1	Predicción cuantitativa de popularidad (0 a 100) basada en atributos de audio y metadatos.	MUST	Señal objetiva de inversión
RF2	Deduplicación estricta por track_id y partición Train/Test estratificada por género musical.	MUST	Prevención de fuga de datos
RF3	Evaluación comparativa contra baseline e informe global de métricas MAE y RMSE.	MUST	Validación técnica Go/No-Go
RF4	Auditoría de equidad con reporte del error por género y frecuencia de reproducciones del artista.	MUST	Mitigación de sesgos algorítmicos
RF5	Ficha de transparencia (Model Card) que	SHOULD	Gobernanza y ética de

ID	Requerimiento funcional y criterio de aceptación	Prioridad	Necesidad de negocio
	documente alcances y limitaciones del dataset.		datos
RF6	Despliegue de API REST en la nube para inferencia en batch o bajo demanda (si se aprueba el Go).	SHOULD	Integración operacional
RF7	Reglas de diversidad en la capa de negocio (cuotas para artistas emergentes y géneros locales).	SHOULD	Evitar el efecto "rich-get-richer"
RF8	Tablero ejecutivo (dashboard) para seguimiento de drift del modelo.	COULD	Monitoreo del piloto

3.2 Requerimientos no funcionales y metas medibles

ID	Requerimiento no funcional (meta medible)	Prioridad	Atributo de calidad
RNF1	Precisión: el MAE global del modelo debe ser al menos 20% menor al del baseline.	MUST	Desempeño predictivo
RNF2	Equidad: el MAE de ningún subgrupo de género debe exceder en más de 30% al MAE global.	MUST	Justicia algorítmica
RNF3	Cumplimiento legal: cumplimiento estricto de la Ley 19.628 y la Ley 21.719 de Chile.	MUST	Privacidad de datos (APDP)
RNF4	Costo presupuestario: el piloto no debe superar el techo de $6.124.740 CLP (3 meses).	MUST	Control financiero
RNF5	Rendimiento de la API: latencia menor a 2,0 segundos en el 95% de las solicitudes.	SHOULD	Disponibilidad operacional
RNF6	Reproducibilidad: control de versiones de código (Git) y de experimentos (MLflow).	SHOULD	Trazabilidad científica
RNF7	Escalabilidad: infraestructura elástica y autosostenible ante incrementos del catálogo.	COULD	Arquitectura cloud

4. Alcance del proyecto

Dentro del alcance: construcción, evaluación algorítmica y despliegue en piloto de un modelo de regresión supervisada, utilizando el Spotify Tracks Dataset (114.000 registros, 21 variables y 114 géneros). Se incluye la deduplicación por track_id, la auditoría de equidad por género, una API REST de inferencia, la ficha de transparencia y el tablero de seguimiento.

Fuera del alcance: sistemas de recomendación en tiempo real, captura dinámica mediante la API de Spotify, reentrenamiento no supervisado y automatización de contratos de talentos sin revisión humana.

5. Evaluación financiera

5.1 Costo empresa y modelo de ROI

Para corregir las estimaciones previas se utiliza el costo empresa real, de $2.247.000 CLP por mes por profesional, que contempla las cargas sociales e impositivas. Con un equipo de 3 integrantes dedicando 20% de su jornada durante 3 meses, el costo en recursos humanos equivale a 1,8 personas-mes, es decir, $4.044.600 CLP.

El modelo de retorno y punto de equilibrio es el siguiente:

Beneficio anual = Δ streams incrementales × ingreso por stream (US$ 0,004) × tipo de cambio ($925 CLP)

Punto de equilibrio = costo del proyecto ($22.200.000 CLP, run-rate anual) / (US$ 0,004 × $925) ≈ 6.000.000 de streams

Un incremento anual de 6 millones de reproducciones, generado por una correcta asignación presupuestaria en canciones con alta probabilidad predictiva, cubre por completo el run-rate anual y entrega un ROI positivo.

5.2 Desglose de costos de infraestructura cloud AWS y presupuesto del piloto

Componente / servicio	Especificación y configuración	Costo mensual (USD)	Total piloto (CLP)
AWS SageMaker Training	Instancia ml.m5.xlarge (20 horas al mes para ajuste)	US$ 115,00	$319.125
AWS SageMaker Endpoint	Instancia ml.t3.medium (inferencia 24/7 en el piloto)	US$ 280,00	$777.000
AWS S3 y CloudWatch	Almacenamiento de datasets, artefactos y logs	US$ 55,00	$152.625
Subtotal infraestructura cloud gestionada (alternativa A, 3 meses)		US$ 450,00	$1.248.750
Recursos humanos (3 personas)	20% de dedicación parcial × 3 meses (costo empresa)	—	$4.044.600
Contingencia y licencias	Reserva para imprevistos operacionales y legales	—	$831.390
Total del piloto			$6.124.740

6. Marco ético y legal de datos

6.1 Análisis de sesgos algorítmicos y feedback loop

El análisis exploratorio reveló brechas estructurales. La popularidad media oscila entre 2,2 (iranian) y 59,3 (pop-film), y artistas consagrados como The Beatles registran 279 entradas frente a una mediana de 1 entrada por artista. Se identifican tres riesgos éticos críticos:

- Sesgo de la etiqueta (popularity label bias): la variable popularity no refleja la calidad intrínseca de una obra, sino el resultado del propio algoritmo de recomendación de Spotify. El modelo corre el riesgo de imitar las preferencias históricas de la plataforma.
- Bucle autocumplido (feedback loop): si la predicción determina qué canciones reciben presupuesto de promoción, esa promoción impulsará la popularidad futura y amplificará el sesgo con cada reentrenamiento.
- Sustituto indirecto de género (explicit content proxy): aunque el contenido explícito representa solo el 8,55% del total, alcanza un 31,9% en el género Hip-Hop. La variable explicit puede actuar como un proxy no deseado de género o demografía y sesgar las evaluaciones.

6.2 Protocolo de auditoría de equidad

Durante la fase de Evaluación (F2) se calculará el MAE para cada uno de los 114 géneros. Se establece el siguiente umbral operativo:

Si MAE del género > 1,30 × MAE global, se activa el congelamiento de inferencia para ese género.

Acción correctora: si un género supera el umbral de 30%, se prohíbe el uso de sus predicciones para decisiones de inversión, se reevalúan las variables predictoras (entrenando variantes sin la variable de fama) y se documenta la limitación de forma explícita en la ficha de transparencia (Model Card).

6.3 Marco legal chileno de protección de datos

Aun cuando el dataset utiliza datos de catálogo público, los nombres de artistas y la caracterización de sus obras constituyen datos personales o personalizables. El proyecto se rige por la Ley 19.628 (sobre protección de la vida privada) y la Ley 21.719, que regula el tratamiento de datos personales y crea la Agencia de Protección de Datos Personales en Chile. Toda la información procesada en el piloto tendrá como único fin el análisis interno del sello, con licencias verificadas y con prohibición de venta o transferencia a terceros.

7. Marco metodológico

Se adopta la metodología CRISP-DM por su alineación con proyectos de minería de datos y por su carácter iterativo. La fase de Evaluación se utiliza como puerta de decisión (decision gate) en la semana 6, en la que el sponsor del sello aprueba o rechaza el paso a producción. Si la decisión es No-Go, se re-preparan los datos o se itera el modelado.

Fase CRISP-DM	Semanas (entregable)	Contenido
1. Comprensión del negocio	Semana 1 (E1)	Requerimientos
2 y 3. Comprensión y preparación de datos	Semanas 1 a 3 (E2)	Deduplicación y EDA
4. Modelado	Semanas 3 a 4 (E3)	Random Forest y Gradient Boosting
5. Evaluación	Semanas 5 a 6 (E4 y E5)	Decisión Go/No-Go
6. Despliegue y piloto	Semanas 9 a 13 (E6, E7 y E8)	API cloud, tablero e informe de ROI final

7.1 Estructura de desglose del trabajo (WBS / EDT)

Paquete de trabajo	Entregables y actividades clave	Responsable	Plazo
1. Gestión de proyecto	1.1 Kick-off y plan de proyecto (E1). 1.2 Control semanal de hitos y costos. 1.3 Informe de cierre con ROI (E8).	Gestor del proyecto	Sem. 1 a 13
2. Comprensión del negocio	2.1 Levantamiento de requerimientos RF/RNF. 2.2 Definición de KPI técnico y de equidad. 2.3 Validación legal de datos.	Gestor y Legal	Sem. 1
3. Preparación de datos	3.1 Análisis EDA de sesgos. 3.2 Deduplicación por track_id. 3.3 Partición estratificada por género (E2).	Analista de datos	Sem. 1 a 3
4. Modelado predictivo	4.1 Construcción del baseline. 4.2 Entrenamiento de Random Forest y Gradient Boosting. 4.3 Registro en MLflow (E3).	Líder técnico	Sem. 3 a 4
5. Evaluación y equidad	5.1 Métricas MAE/RMSE globales (E4). 5.2 Auditoría por género (brecha de MAE ≤ 30%). 5.3 Model Card (E5). 5.4 Hito Go/No-Go.	Líder técnico y analista	Sem. 5 a 6
6. Despliegue y piloto	6.1 API REST en AWS (E6). 6.2 Reglas de diversidad en la capa de negocio. 6.3 Dashboard de seguimiento (E7).	Líder técnico	Sem. 9 a 13

8. Cronograma e hitos

El proyecto comprende 13 semanas de ejecución. Las semanas 7 y 8 corresponden a un buffer de contingencia para ajustes de modelos antes del despliegue en la semana 9.

Hito	Descripción	Semana	Condición de cumplimiento (criterio de aceptación)
H1	Requerimientos y alcance aprobados	Semana 1	Documento E1 firmado por el sello y validación legal de datos.
H2	Dataset preparado y deduplicado	Semana 3	Dataset E2 sin duplicados de track_id y con partición estratificada.
H3	Modelos candidatos entrenados	Semana 4	Baseline y al menos 2 modelos no lineales registrados en MLflow (E3).
H4	Auditoría de equidad finalizada	Semana 5	Informe E4 presentado con MAE global y reporte por subgrupo de género.
H5	Decisión Go/No-Go	Semana 6	Aprobación si el MAE mejora al menos 20% y ningún género supera en más de 30% al MAE global.
H6	API REST en producción cloud	Semana 10	Endpoint AWS SageMaker operativo con latencia menor a 2,0 s (E6).
H7	Dashboard y reglas activas	Semana 11	Tablero E7 operativo y reglas de diversidad aplicadas en el negocio.
H8	Cierre formal del proyecto	Semana 13	Informe final E8 con ROI verificado y entrega de la Model Card final.

9. Gestión de riesgos

Los riesgos se evalúan en una escala de 1 a 5, donde Severidad = Probabilidad (P) × Impacto (I). La clasificación es: Bajo (1 a 6), Medio (8 a 12) y Alto (15 a 25).

#	Riesgo identificado	P	I	P×I	Nivel	Estrategia de mitigación	Indicador de alerta
R1	Fuga de datos por track_id duplicado entre Train y Test	4	5	20	ALTO	Deduplicación estricta y agrupamiento previo a la división.	Registros repetidos en EDA > 0%
R2	Incumplimiento del umbral técnico por bajo poder predictivo	4	5	20	ALTO	Modelos no lineales (GBM) y variables de contexto.	MAE en sem. 5 no mejora ≥ 20% ⇒ No-Go
R3	Sesgo algorítmico cultural contra géneros	4	5	20	ALTO	Auditoría por género y cuotas en la capa de negocio.	MAE del género > 1,30 × MAE

#	Riesgo identificado	P	I	P×I	Nivel	Estrategia de mitigación	Indicador de alerta
	emergentes						global
R4	Infracción de los Términos de Servicio de la API de Spotify	4	5	20	ALTO	Uso estrictamente analítico e interno, sin comercializar datos.	Observación del área Legal
R5	Desviación de presupuesto por sobrecostos cloud	3	3	9	MEDIO	Alertas automáticas en AWS Budgets al alcanzar 80%.	Gasto acumulado > US$ 360