# Informe de Factibilidad

Análisis ético, financiero y de riesgos del proyecto de predicción de popularidad de canciones en Spotify

| | |
|---|---|
| **Asignatura** | Gestión de Proyectos de Datos (SCY1102) — Evaluación Parcial N°1 |
| **Institución** | Duoc UC |
| **Integrantes** | Lucas Concha Perez · Natalia Hormazabal Nuñez · Martín Villarroel Morales |

El presente informe evalúa la factibilidad del proyecto de Machine Learning cuyo objetivo es predecir el nivel de popularidad (0–100) de una canción en Spotify a partir de sus atributos de audio y metadatos, con el fin de apoyar decisiones de programación de playlists, campañas promocionales y fichaje de talento (A&R). El análisis se basa en el conjunto de datos *Spotify Tracks Dataset* (114.000 registros, 21 columnas, 114 géneros musicales) y en el trabajo de preparación de datos ya realizado por el equipo (limpieza, tratamiento de nulos y duplicados, codificación de variables categóricas y escalamiento), documentado en el repositorio del proyecto. A continuación se desarrollan los tres ejes solicitados: análisis ético, evaluación financiera y análisis de riesgos.

## 1. Análisis ético

### 1.1 Identificación de sesgos en los datos

La revisión de calidad de datos y el análisis exploratorio realizado por el equipo permiten identificar los siguientes sesgos relevantes para el modelamiento:

- **Sesgo cultural / de género musical:** si bien el dataset está perfectamente balanceado en volumen (exactamente 1.000 pistas por cada uno de los 114 géneros), la popularidad promedio varía drásticamente entre géneros: *iranian* (2,2 pts) y *romance* (3,2 pts) frente a *pop-film* (59,3 pts) y *k-pop* (56,9 pts). Esta brecha no refleja necesariamente diferencias de calidad musical, sino la exposición desigual de géneros no occidentales o de nicho en el algoritmo y en la base de usuarios de la plataforma.
- **Sesgo de "artista ya establecido" (efecto Mateo):** la variable *artists* está altamente concentrada: The Beatles aparece en 279 registros, George Jones en 271, Stevie Wonder en 236, frente a una mediana de solo 1 registro por artista (31.437 artistas únicos). Un modelo que capture esta señal tiende a reforzar la visibilidad de artistas ya consagrados en desmedro de talento emergente.
- **Baja correlación lineal de las variables de audio con la popularidad** (todas las correlaciones de Pearson son inferiores a 0,1 en valor absoluto, p. ej. *danceability* = 0,035, *loudness* = 0,050, *instrumentalness* = –0,095). Esto sugiere que la popularidad está determinada en mayor medida por factores extra-musicales (marketing, posicionamiento en playlists, fama del artista) no capturados por los atributos acústicos, lo que expone al modelo al riesgo de aprender proxies de fama en lugar de calidad musical.
- **Riesgo de fuga de datos (data leakage):** el 35,9% de las filas comparten un mismo *track_id* repetido bajo distintos géneros, y se detectaron 450 duplicados exactos. Si estas filas no se agrupan correctamente antes de dividir entrenamiento y prueba, el modelo puede memorizar pistas en lugar de generalizar.
- **Baja representación de contenido explícito** (solo 8,55% de las pistas están marcadas como *explicit*), lo que puede sub-representar ciertos géneros (p. ej. hip-hop, reguetón) en los que este atributo es más frecuente.

### 1.2 Impactos éticos potenciales del modelo o solución propuesta

Si estos sesgos no se gestionan, el uso del modelo para decisiones de negocio (curaduría de playlists, inversión publicitaria, fichaje de artistas) puede generar los siguientes impactos:

- **Reducción de diversidad cultural:** subestimar sistemáticamente la popularidad potencial de géneros no occidentales o emergentes reduce la inversión y visibilidad que reciben, perpetuando la brecha observada en los datos.
- **Efecto "rich-get-richer":** al asociar popularidad con artistas ya frecuentes en el catálogo, el modelo puede recomendar reforzar la promoción de quienes ya son exitosos, reduciendo oportunidades para artistas independientes o nuevos.
- **Retroalimentación autocumplida (feedback loop):** si las predicciones del modelo influyen en decisiones de promoción, y esa promoción determina la popularidad futura real, el sesgo inicial se amplifica con cada ciclo de reentrenamiento.
- **Decisiones de negocio poco fundamentadas:** dado el bajo poder explicativo de los atributos de audio, usar el modelo como único criterio de inversión (p. ej. en A&R) puede llevar a decisiones erradas si no se comunican adecuadamente sus límites de confianza.

### 1.3 Medidas para mitigar sesgos o riesgos éticos

1. Deduplicar por *track_id* y aplicar una división entrenamiento/prueba estratificada por género antes de modelar, evitando fuga de datos entre particiones.
2. Realizar auditorías de equidad (*fairness audits*): reportar el error del modelo (MAE/RMSE) desagregado por género musical y por nivel de frecuencia del artista, para detectar y documentar disparidades de desempeño.
3. Excluir o tratar con cautela variables proxy de fama del artista, evaluando su aporte real frente al riesgo de sesgo, y explorando variantes del modelo con y sin dicha variable.
4. Mantener supervisión humana (*human-in-the-loop*): usar las predicciones como una señal complementaria y no como criterio único para decisiones de inversión, programación o fichaje de artistas.
5. Incorporar reglas de diversidad en la lógica de negocio que consume las predicciones (p. ej. cuotas mínimas de exposición para artistas emergentes o géneros subrepresentados).
6. Documentar las limitaciones del dataset y del modelo mediante una ficha de transparencia ("model card"/"datasheet") accesible para los equipos de negocio que tomen decisiones con base en sus resultados.

## 2. Evaluación financiera

Se estima el costo de llevar el proyecto desde su estado actual (datos limpios y preparados, según el notebook del equipo) hasta un piloto productivo de 3 meses que incluya modelamiento, evaluación y despliegue de una API de predicción. Los valores son estimaciones referenciales en USD, basadas en tarifas públicas de proveedores cloud (Amazon Web Services, s.f.; Google Cloud, s.f.) y en dedicación parcial del equipo.

### 2.1 Estimación de costos por alternativa

| Categoría de costo | Alt. A — Cloud gestionado | Alt. B — Infraestructura propia / OSS |
|---|---|---|
| Infraestructura cloud (cómputo, almacenamiento, hosting de API) | USD 450/mes × 3 = **USD 1.350** | USD 80/mes × 3 = **USD 240** (VPS liviano + backup) |
| Licencias de software (MLOps/AutoML, BI) | USD 300/mes × 3 = **USD 900** | Stack 100% open source (pandas, scikit-learn) + BI opcional = **USD 150** |

| Categoría de costo | Alt. A — Cloud gestionado | Alt. B — Infraestructura propia / OSS |
|---|---|---|
| Recursos Humanos (equipo de 3 personas, dedicación parcial, 3 meses) | ~20% jornada c/u = **USD 9.000** | ~30% jornada c/u por mayor carga operativa manual = **USD 12.000** |
| Agentes o servicios automáticos (CI/CD, monitoreo de modelo, ETL programado) | USD 400/mes × 3 = **USD 1.200** | Scripts propios, sin soporte comercial = **USD 0** |
| **Total estimado (3 meses)** | **USD 12.450** | **USD 12.390** |

### 2.2 Comparación costo–beneficio de alternativas

- **Alternativa A (cloud gestionado — AWS SageMaker / GCP Vertex AI):** mayor costo en infraestructura y licencias, pero menor carga de Recursos Humanos gracias a auto-escalamiento, monitoreo y despliegue gestionados. Ofrece mayor velocidad de iteración (*time-to-market*), escalabilidad ante crecimiento del dataset y respaldo de SLA del proveedor. Riesgo: dependencia del proveedor (*vendor lock-in*) y posible escalamiento de tarifas.
- **Alternativa B (infraestructura propia / open source):** menor gasto directo en infraestructura y licencias, pero mayor dedicación de Recursos Humanos para tareas de administración, monitoreo y mantenimiento manual, sin garantías contractuales de disponibilidad. Ofrece mayor control sobre los datos y ningún costo de licenciamiento recurrente, a costa de mayor riesgo operacional y menor velocidad de despliegue.

### 2.3 Justificación de la alternativa seleccionada

El costo total estimado a 3 meses es prácticamente equivalente entre ambas alternativas (USD 12.450 frente a USD 12.390). Dado que el proyecto se encuentra aún en la etapa de preparación de datos dentro del marco CRISP-DM (modelamiento, evaluación y despliegue están pendientes) y que el equipo es reducido —tres integrantes sin dedicación exclusiva a labores de DevOps/MLOps—, se recomienda adoptar la **Alternativa A (cloud gestionado)** para la fase piloto. Esta opción reduce el riesgo operacional, acelera la iteración entre modelado y evaluación, y facilita escalar la solución si el catálogo de canciones crece más allá de los 114.000 registros actuales. Se recomienda reevaluar una eventual migración hacia infraestructura propia (Alternativa B) una vez validado el modelo en producción y estabilizado el volumen de uso, con el fin de reducir costos recurrentes de licenciamiento.

## 3. Análisis de riesgos

La matriz siguiente clasifica los riesgos identificados en técnicos, legales, financieros y éticos, evaluando su probabilidad e impacto en una escala de Alta / Media / Baja, junto con la estrategia de mitigación propuesta.

| # | Riesgo | Categoría | Prob. | Impacto | Mitigación |
|---|---|---|---|---|---|
| 1 | Fuga de datos por duplicidad de track_id entre géneros (35,9% de las filas) | Técnico | Alta | Alta | Deduplicar por track_id y agrupar en la validación cruzada antes de dividir train/test. |
| 2 | Bajo poder predictivo por correlación lineal débil (<0,1) entre audio y popularidad | Técnico | Alta | Media | Usar modelos no lineales (Random Forest, Gradient Boosting), sumar variables de contexto y ajustar expectativas de negocio. |
| 3 | Escalabilidad insuficiente ante crecimiento del catálogo | Técnico | Media | Media | Arquitectura cloud elástica (Alternativa A) con auto-escalamiento. |
| 4 | Uso de datos sujetos a los Términos de Servicio de la API de Spotify | Legal | Media | Alta | Verificar la licencia del dataset y restringir su uso a fines analíticos internos; validar con área legal antes de un despliegue comercial. |

| # | Riesgo | Categoría | Prob. | Impacto | Mitigación |
|---|---|---|---|---|---|
| 5 | Tratamiento de datos personales de artistas (nombres) bajo normativa de protección de datos | Legal | Baja | Media | Agregar/anonimizar datos cuando no se requiera identificación individual y definir base de licitud del tratamiento. |
| 6 | Sobrecosto por dependencia de servicios cloud gestionados (vendor lock-in) | Financiero | Media | Media | Monitoreo de consumo, alertas de presupuesto y revisión trimestral de costos. |
| 7 | Bajo retorno de inversión si el modelo no alcanza el KPI técnico esperado (RMSE/MAE) | Financiero | Media | Alta | Definir umbrales mínimos de aceptación (go/no-go) antes de invertir en el despliegue completo. |
| 8 | Sesgo cultural que perpetúa baja exposición de géneros no occidentales (ej. iranian: 2,2 pts vs. pop-film: 59,3 pts) | Ético | Alta | Alta | Auditorías de equidad por subgrupo y supervisión humana en decisiones de inversión/A&R. |
| 9 | Efecto "rich-get-richer" que refuerza la exposición de artistas ya populares | Ético | Media | Media | Incorporar reglas de diversidad/exploración en la lógica de negocio que consume las predicciones. |

En síntesis, los riesgos de mayor criticidad (probabilidad y/o impacto "Alto") son la fuga de datos por duplicidad de *track_id*, el sesgo cultural que subrepresenta géneros no occidentales, el cumplimiento de los Términos de Servicio de Spotify y el eventual bajo retorno de inversión si el modelo no cumple el KPI técnico definido. Estos cuatro riesgos deben abordarse antes de avanzar de la fase de preparación de datos a la de modelamiento y despliegue.

## Referencias


Amazon Web Services. (s. f.). Precios de Amazon SageMaker. AWS. https://aws.amazon.com/es/sagemaker/pricing/

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.

Google Cloud. (s. f.). Precios de Vertex AI. https://cloud.google.com/vertex-ai/pricing

Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K., & Galstyan, A. (2021). A survey on bias and fairness in machine learning. *ACM Computing Surveys, 54*(6), 1–35. https://doi.org/10.1145/3457607

Ministerio Secretaría General de la Presidencia de Chile. (1999). *Ley N.º 19.628 sobre Protección de la Vida Privada*. Biblioteca del Congreso Nacional de Chile. https://www.bcn.cl/leychile/navegar?idNorma=141599

Pandya, M. (2022). *Spotify Tracks Dataset* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/maharshipandya/-spotify-tracks-dataset

Spotify. (s. f.). *Web API*. Spotify for Developers. https://developer.spotify.com/documentation/web-api